



國立臺灣科技大學

工業管理系

碩士學位論文

學號：M10401303

---

應用 SVR 於預測性維修中衰退狀態資料之預測



**Applying SVR to predict degradation data in  
predictive maintenance**

研 究 生：吳俊諺

指導教授：王福琨 博士

中 華 民 國 一 〇 六 年 六 月



M10401303



## 碩士學位論文指導教授推薦書

本校 工業管理系 吳俊諺(WU, CHUN-YEN) 君

所提之論文：

應用SVR於預測性維修中衰退狀態資料之預測

係由本人指導撰述，同意提付審查。

指導教授：王福琨

指導教授

王福琨

106 年 6 月 8 日



# 碩士學位考試委員審定書



M10401303

指導教授：王福琨

本校 工業管理系 吳俊諺 君

所提之論文：

應用SVR於預測性維修中衰退狀態資料之預測

經本委員會審定通過，特此證明。

學校考試委員會

委員：

邱啟之

陳欽雨

王福琨

指導教授：

王福琨

學程主任：

系(學程)主任、所長：

曹蒼隆

中華民國 106年 6月 8 日

## 摘要

隨著科技的進步，生產設備也日趨精密與昂貴，系統的維護也相對的重要。其中預測性維修是對機台進行狀態監測，並在機台發生故障前進行維修，能使機台無預警失效的機率大幅下降。由於現在感測器的普及，精密及昂貴的生產設備都會裝上感測器，隨時監控機台狀態，能有效減少機台忽然停擺的龐大損失，預測維修已成為日後任何設備保養的必備趨勢。故本研究提供一個預測性維修的方法，運用支持向量回歸對物件進行狀態衰退預測，並算出物件剩餘使用壽命，掌握物件健康狀況，並預知可能失效的時間點，以避免系統失效的狀況發生。本研究在案例一中兩個測試零件的剩餘使用壽命如下：(37.10%，80.24%， Sutrisno *et al.*，2012)，(5.32%，2.06%，本研究)，可見本研究的結果比較準確，在案例二中使用滾動式預測可以解決長區間預測不準確問題。

**關鍵字：**預測性維修、支持向量回歸、剩餘使用壽命、滾動式預測。



## Abstract

The production equipment is becoming more sophisticated and expensive as the progress of science and technology, the maintenance is also more important. Predictive maintenance is to monitor the condition of the machine and repair the machine before it breaks down. It will reduce the probability of the failure of the machine without warning. Due to the popularity of sensors, the precision and expensive production equipment will be installed sensor and monitor state at any time, it can effectively reduce the huge loss of the machine suddenly shut down. Predictive maintenance has become a necessary trend on any of the equipment maintenance. It provides a predictive maintenance method in this study, we use the support vector regression to predict the degradation of object status and calculate the object remaining useful life for predict the possible failure time, it can avoid occurring the system failure. The remaining use life of two test parts in case one is following below: (37.10%, 80.24%, Sutrisno *et al.*, 2012), (5.32%, 2.06%, in this study), the results of this study are more accurate. In case 2, rolling forecast is used to solve the problem of inaccurate prediction of long range.

Keywords: Predictive Maintenance, Support Vector Regression, Remaining Useful Life, Rolling Forecast.

## 致謝

短短兩年碩士時光，時光飛逝，當初剛入學到現在即將畢業的我，真的進步很多。在這兩年的碩士期間我學習到許多，其中專業知識與相關的訓練更讓我擁有不同的思維與認知。感謝指導教授王福琨老師給予細心的指導，老師總是能在我需要幫助的時候給予建議，並給我適當的鼓勵與幫助。也要感謝每一位研究室成員給予我的鼓勵與動力，在課業或生活上多增添些色彩。

同時非常感謝口試委員的撥冗審閱及細心匡正，給予本研究諸多的寶貴建議與指導，使本研究內容更加充實，僅在此致上由衷的謝意。

最後，要感謝我的家人一路支持我的決定，因為你們的支持與鼓勵，使我得以學習知識，體悟不同的觀念，往後的人生也充滿著不同的見解與看法。在此，謹以此論文獻給我親愛的家人與所有曾經給予幫助及關係我的人們，並在此深深表達我對你們的敬意與謝意。謝謝你們。



# 目錄

摘要.....	IV
Abstract.....	V
致謝.....	VI
目錄.....	VII
圖目錄.....	IX
表目錄.....	XI
第一章 緒論.....	12
1.1 研究背景與動機.....	12
1.2 研究目的.....	13
1.3 研究範圍與限制.....	13
1.4 研究流程.....	13
.....	14
第二章 文獻回顧.....	15
2.1 維修的策略.....	15
2.1.1 矯正性維修.....	15
2.1.2 預防性維修.....	16
2.1.3 預測性維修.....	16
2.2 預測的方法.....	20
第三章 研究方法.....	23
3.1 支持向量回歸.....	23
3.1.1 線性向量支持回歸.....	23
3.1.2 非線性向量支持回歸.....	25
3.2 參數的選擇方法.....	26

3.3 滾動式預測.....	27
<b>第四章 案例分析.....</b>	<b>29</b>
4.1 個案 1- Ball Bearings Data .....	29
4.2 個案 2 -PV data.....	40
<b>第五章 結論與建議.....</b>	<b>49</b>
<b>參考文獻.....</b>	<b>50</b>
<b>附錄.....</b>	<b>52</b>





## 圖目錄

圖 1 研究流程.....	14
圖 2.1 維修種類.....	15
圖 2.2 維修時機.....	16
圖 2.3 維修成本.....	17
圖 2.4 預測性維修的技術體系.....	18
圖 2.5 即時監測和預測流程圖(SVM 為例) .....	19
圖 3.1 原始資料從原始空間透過轉換到較高維度的空間.....	25
圖 3.2 傳統預測合滾動式預測比較圖.....	27
圖 3.3 滾動式預測概念圖.....	28
圖 4.1 實驗平台圖.....	29
圖 4.2 Ball Bearings 衰退前後和衰退過程振幅圖.....	30
圖 4.3 Bearing1_1 2000# Horizontal 2560 個點取絕對值最大五個點 .....	31
圖 4.4 Bearing1_1 衰退資料 .....	31
圖 4.5 Bearing1_4 衰退資料 .....	32
圖 4.6 Bearing1_1 溫度資料 .....	32
圖 4.7 Bearing1_4 溫度資料 .....	33
圖 4.8 Bearing1_1 (未入溫度)衰退預測 .....	33
圖 4.9 Bearing1_4 (未入溫度)衰退預測 .....	34
圖 4.10 Bearing1_1 (加入溫度)衰退預測 .....	34
圖 4.11 Bearing1_4 (加入溫度)衰退預測 .....	35
圖 4.12 Bearing1_1 衰退趨勢和異常圖 .....	36
圖 4.13 Bearing1_1 第一次警告到第二次警告趨勢圖 .....	36
圖 4.14 Bearing1_3 第一次警告到 Horizontal 超過閾值趨勢圖 .....	37
圖 4.15 Bearing1_3 實際衰退與 Exponential 預測衰退趨勢圖 .....	37

圖 4.16 Bearing1_4 第一次警告到 Horizontal 超過閾值趨勢圖 .....	38
圖 4.17 真實電壓衰退趨勢.....	41
圖 4.18 RMS 趨勢 .....	41
圖 4.19 滾動式預測作法.....	42
圖 4.20 實際衰退和 SVR 預測結果 .....	42
圖 4.21 實際衰退與 SVR 先學習後預測結果 .....	43
圖 4.22 實際衰退和 SVR 預測第 44 月到第 49 月結果 .....	44
圖 4.23 實際衰退和 SVR 預測第 50 月到第 55 月結果 .....	44
圖 4.24 實際衰退和 SVR 預測第 56 月到第 61 月結果 .....	45
圖 4.25 實際衰退和 SVR 預測第 62 月到第 67 月結果 .....	45
圖 4.26 實際衰退和 SVR 預測第 68 月到第 73 月結果 .....	46
圖 4.27 實際衰退和 SVR 預測第 74 月到第 79 月結果 .....	46
圖 4.28 實際衰退和 SVR 預測第 80 月到第 85 月結果 .....	47



## 表目錄

表 2.1 自動車車輪衰退資料.....	21
表 2.2 經典模型和 SVR 的預測比較.....	22
表 2.3 MAPE 對模型的評估 .....	222
表 4.1 Datasets of IEEE 2012 PHM Prognostic Challenge .....	30
表 4.2 Learning Bearing1_1 , Test Bearing 1_4 (未加入溫度).....	33
表 4.3 Learning Bearing1_1 , Test Bearing 1_4 (加入溫度).....	34
表 4.4 真實 RUL 時間.....	39
表 4.5 預測 RUL 的錯誤率.....	40
表 4.6 Method 1 和 Method 2 的參數和 MAPE 比較表.....	47



# 第一章 緒論

## 1.1 研究背景與動機

所有的工業系統或機械都會因為操作的狀況不同產生衰退的過程，而這衰退的情況可能會造成系統或機械無預期的停擺，而且需要立即的維修。像現今高科技產業中，若一個生產機台內有個物件或模組發生故障，可能會導致整個生產機台突然停擺或產生功能異常，而造成重大損失。現在還有很多工業是使用矯正維修 (Corrective Maintenance, CM) 的方式，是一種以設備是否為完好能用為依據，只在設備部分或全部故障時才再修復到原始狀態。而目前最普遍的維修方式為預防性維修 (Preventive Maintenance, PM)，考慮可靠度的計算 (Francis, 1988)，像是利用過去失效資訊計算平均故障間隔 (Mean Time Before Failures, MTBF)、故障前平均時間 (Mean Time To Failure, MTTF)，或是依據生產計畫和過去經驗，按規定的時間間隔進行停機檢查、解體、更換零件，以預防損壞和續發性的毀壞及生產損失。而這仍然有缺失，被替換的零件並沒有考慮零件實際的健康狀態，也許還能使用更久或已經在預計時間內就壞了，就只能算出可能的平均故障時間間隔。因此，隨後發展出預測性維修 (Predictive Maintenance, PdM)，是一種對機台主要或部分安裝感測器 (Sensor)，進行狀態監測和故障診斷，預測機台未來狀態的發展趨勢，依據機台的狀態和可能的故障模式，預先制定預測性維修計劃，確定機器應該修理的時間、內容、方式和必需的技術和物資支持。所以這種維修方法能在機台有異常的徵兆時，並預測出其剩餘使用壽命 (Remaining Useful Life, RUL)，且根據其狀況在損壞之前更換零件或安排保養的時程，如此可以避免機台無預警之失效，減少機台突然停擺所帶來的大量損失。隨著大數據的時代來臨，資訊科技的進步使電腦運算能力更強，在資料處理上將未知潛在有用的資訊轉換成有價值的資訊，預測維修已成為日後任何設備保養的必備趨勢。

## 1.2 研究目的

隨著科技的進步，生產設備也日越精密與昂貴，系統的維護也相對的重要。擁有好的維護策略不僅能降低生產系統的失效機率，更能充分發揮系統效益。

以往都是使用矯正性維修和預防性維修，這些維修策略通常只適用在維護較容易且成本較低者。然而，高科技產業的設備十分昂貴，若發生無預警的停機、失效或系統故障，將導致龐大的停工損失。因此，現在發展出預測性維修，透過設備狀態監測、故障診斷和狀態預測去做出維修策略，在設備發生異常時，能即時做維修，以達到降低無預警停機的機會發生。本研究將針對預測性維修內狀態監測做探討，藉由設備衰退數據，利用支持向量回歸 (Support Vector Regression, SVR) 預測出設備的衰退趨勢，並計算出剩餘使用壽命，找出最佳維修時間，讓系統降低無預警的停機，使系統可以達到最佳效益。

## 1.3 研究範圍與限制

本研究預測性維修的建立限制用於有衰退趨勢的資料。預測方法是以 SVR 為主。

## 1.4 研究流程

本研究共分成五章，在第一章介紹了研究動機、研究目的與研究限制，第二章針對不同的維修方式和預測方法進行文獻回顧和探討，第三章介紹本研究狀態預測的方法 SVR，第四章分為兩個個案，使用不同的方式對物件進行狀態預測，在第五章對本研究提出結論與未來研究方向，本研究流程如圖 1.1。



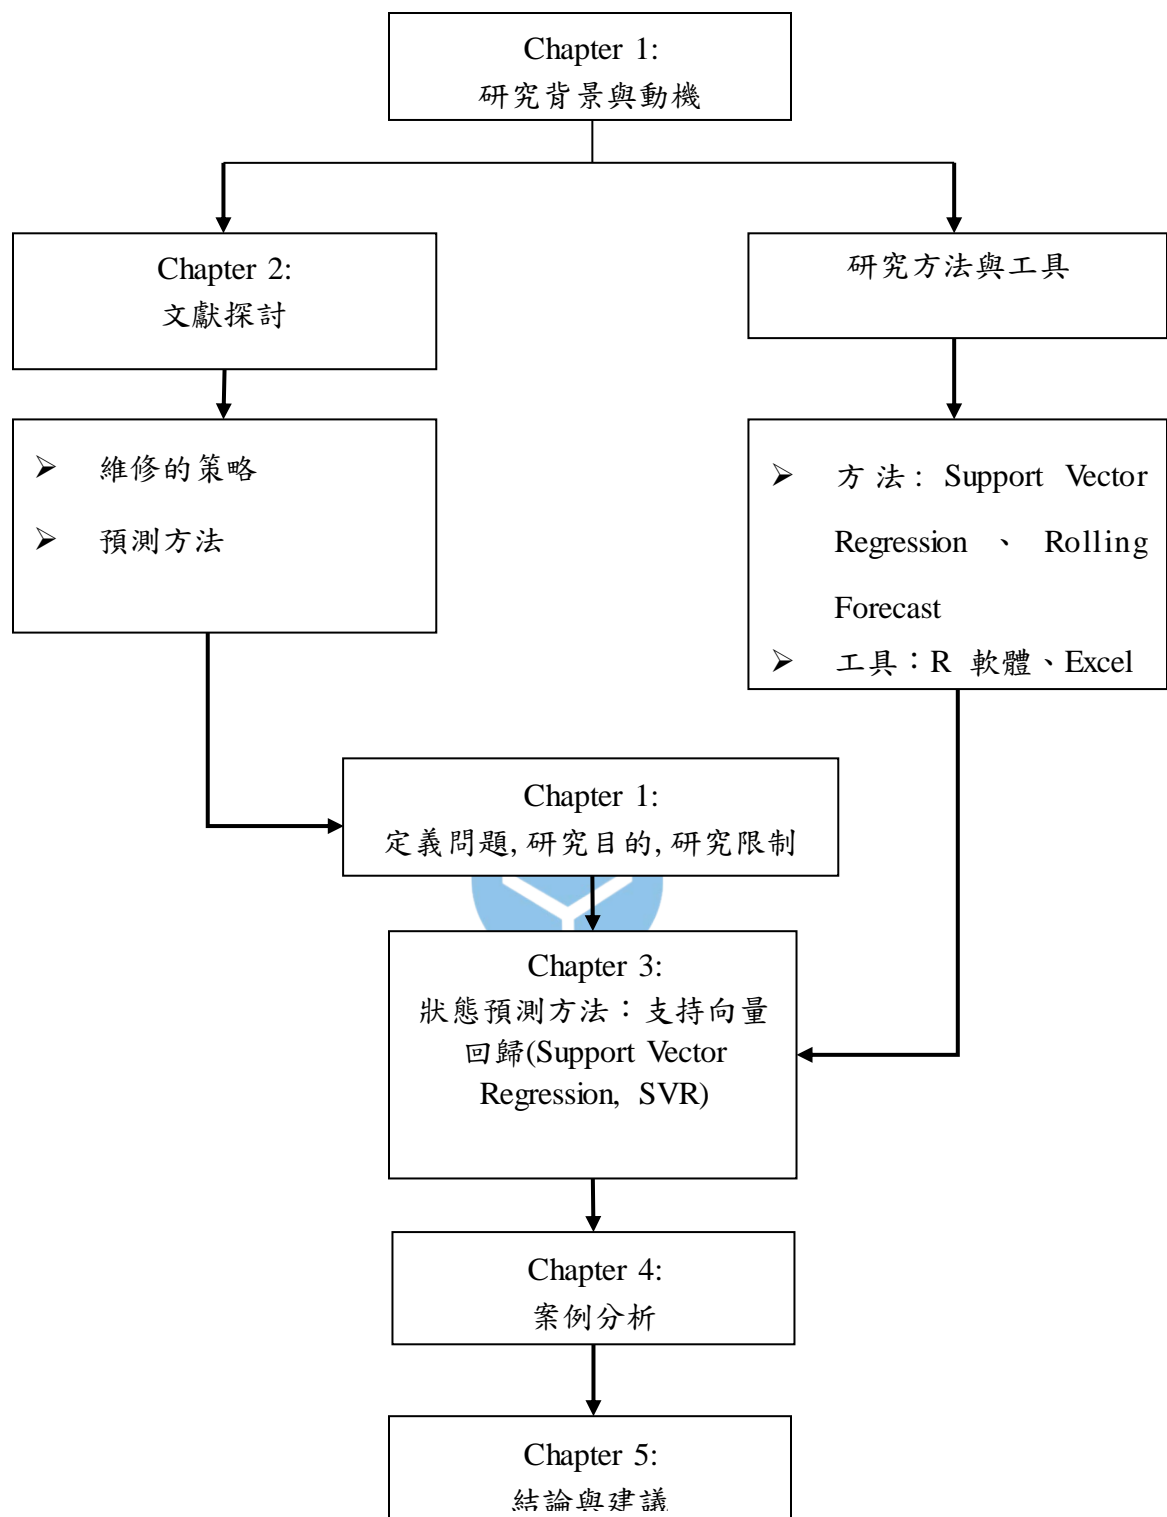


圖 1 研究流程

## 第二章 文獻回顧

### 2.1 維修的策略

對於維修 (Maintenance) 的定義，顧尚芳 (2003) 有整理出，是運用全部必需的處置與機能，去維持一個項目在可用及可運轉之條件，或去除故障、失效，使其恢復(依日本工業標準 JIS-Z8115 之定義)。系統的維修管理的目的在於維持系統的可用狀態，並確保原始設計的能力。Budai-Balke (2009) 和顧尚芳 (2003) 有提到，系統維修類型可分為三類，分別是矯正性維修、預防性維修、預測性維修。整理如圖 2.1 所示。三種維修類型定義如下：

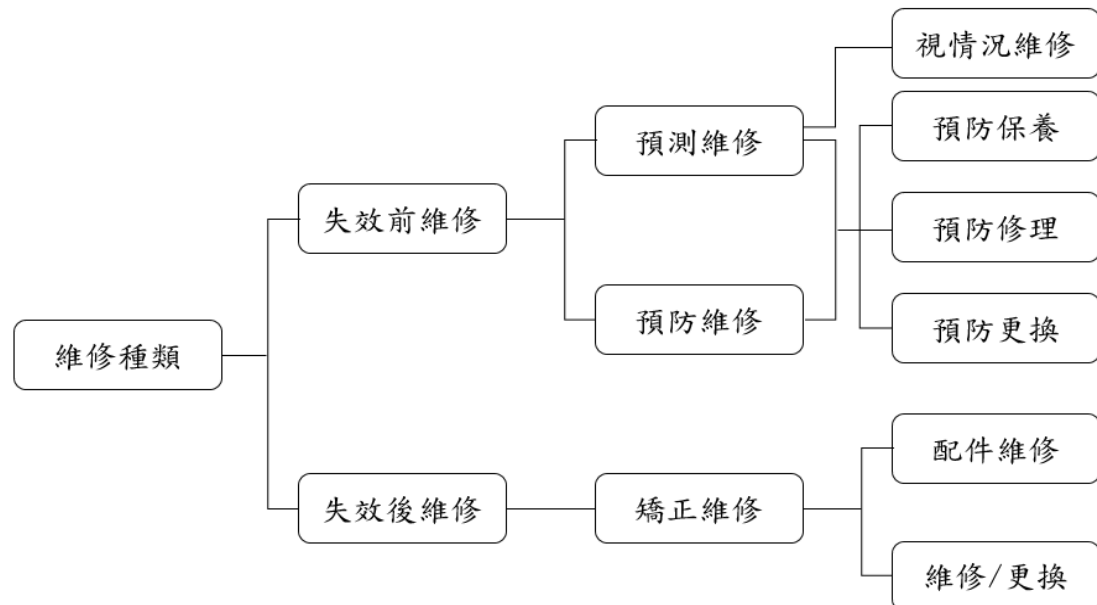


圖 2.1 維修種類

資料來源：整理自顧尚芳 (2003) 和 MBA 智庫百科 (2016)

#### 2.1.1 矯正性維修

當發現設備故障時，立即進行維修。並把現有設備的缺點，有計畫性的加以改善，藉以減少故障或劣化。其不考慮系統的失效時間點，只有在系統失效或異常警訊時，才進行即時處理。這種維修成本通常較高，所以通常運用在設備本身價格較低。

### 2.1.2 預防性維修

預防性維修是一種依計畫定期實施檢查、維修、更換部分零件等維護工作，使得生產設備發生輕微異常或失效前，就能透過預先排定的定期保養檢查工作，將可能發生損壞的部分進行修正，為時間為主 (Time-Based) 的維護方式。而這種維修策略，在進行維修前並未確認更換物件的健康程度，如果在物件還健康的時候替換新的，就會增加維修零件的使用量。或者因為維修週期過長，來不及在系統失效前維修，造成額外的停機成本。因此這種過久或不必要的預防性維修，容易產生維修資源浪費的情況。

### 2.1.3 預測性維修

預測性維修最早在西方發達工業國家興起，PdM 一般翻譯為預測性維修或預知性維修，而預測維修和預知維修與前面的翻譯相比，僅僅是多字少字的問題。有時 CBM 也被翻譯為預測性維修，因為它的英文原意就是對 PdM 的概念解釋；On-condition Maintenance 一般翻譯為視情維修。

預測性維修為經由連續地監測各參數狀態和故障診斷，或經由歷史資料預估故障發生的時機，在設備發生異常或故障前給予適當的維修，避免發生無預警的故障，能減少停機的成本。維修的時機和維修的成本如圖 2.2、圖 2.3 所示。

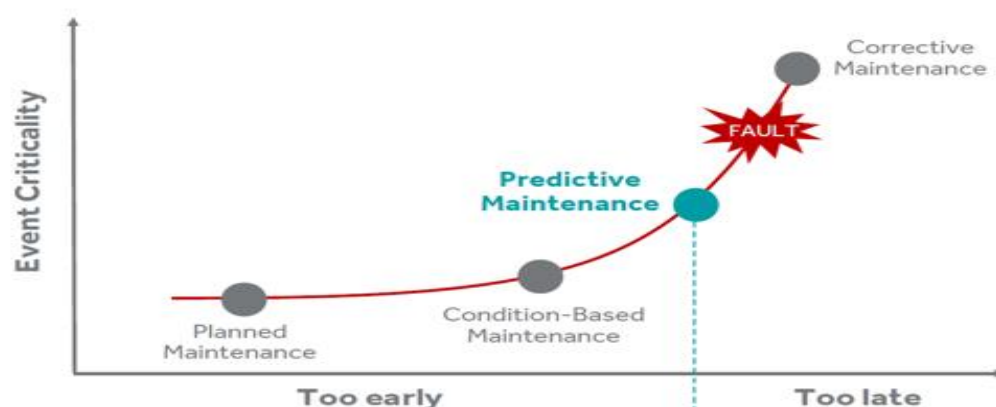


圖 2.2 維修時機

資料來源：Dataconomy (2015)



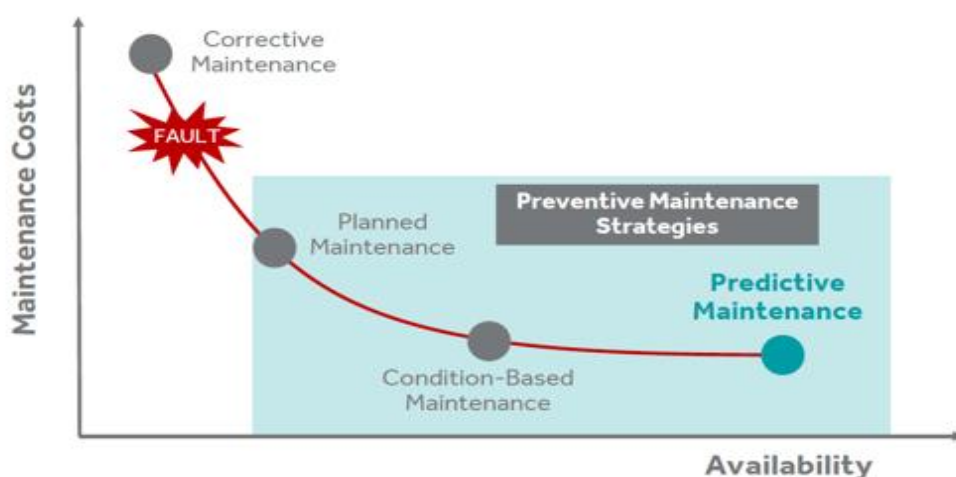


圖 2.3 維修成本

資料來源： Dataconomy (2015)

預測性維修集裝備狀態監測、故障診斷、故障（狀態）預測、維修決策支持和維修活動於一體，是一種新興的維修方式。辜樹仁 (2016) 在天下雜誌有刊登，設計製造飛機、船艦引擎與發電機的全球第二大動力系統製造商英國勞斯萊斯，就將引擎安裝二十到三十個感測器，隨時收集轉速、溫度、震動、油壓等各種運轉數據，並透過衛星回傳在德比的監控中心，進行即時分析，和幾千筆資料做比對，檢視引擎是否正常運轉。若發現任何數據異常，客服人員就會馬上通知飛行員及航空公司，派遣勞斯萊斯維修人員提早檢修，避免引擎發生無預警故障。

狹義的預測性維修立足於“狀態監測”，強調的是“故障診斷”，是指不定期或連續地對設備進行狀態監測，根據其結果，查明裝備有無狀態異常或故障趨勢，再適時地安排維修。狹義的預測性維修不固定維修周期，僅僅通過監測和診斷到的結果來適時地安排維修計劃，它強調的是監測、診斷和維修三位一體的過程，這種思想廣泛適用於流程工業和大規模生產方式。

廣義的預測性維修將狀態監測、故障診斷、狀態預測和維修決策多位合一體，狀態監測和故障診斷是基礎，狀態預測是重點，維修決策得出最終的維修活動要

求。廣義的預測性維修是一個系統的過程，它將維修管理納入了預測性維修的範疇，通盤考慮整個維修過程，直至得出與維修活動相關的內容。預測性維修發展到現在，基本上形成了自己的技術體系，如圖 2.3 所示，預測維修流程如圖 2.4 所示。

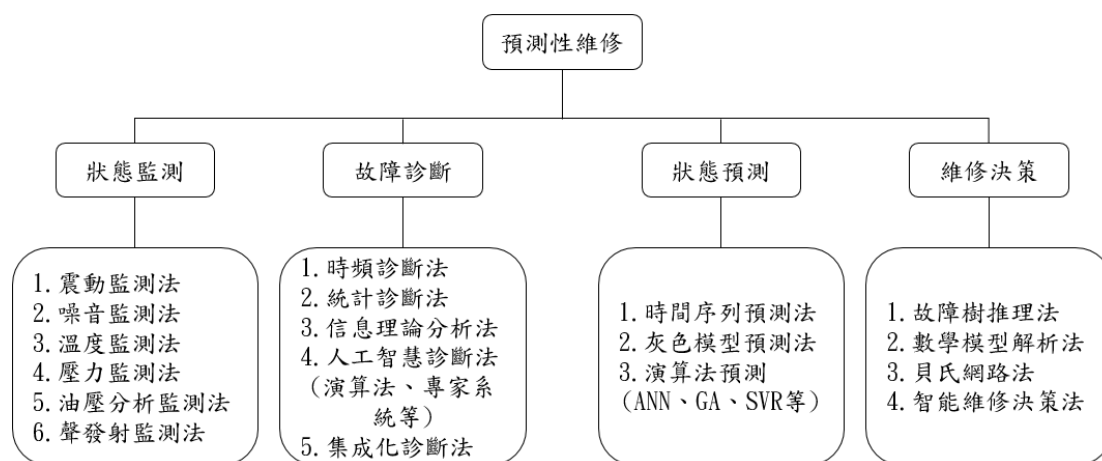


圖 2.4 預測性維修的技術體系

資料來源：整理自 MBA 智庫百科 (2016)

### 1. 狀態監測技術

狀態監測技術發展到現在，在各工程領域都形成了各自的監測方法，狀態監測的方法依據狀態檢測手段的不同而分成許多種，常用的包括：振動監測法、雜訊監測法、溫度監測法、壓力監測法、油液分析監測法、聲發射監測法等。

### 2. 故障診斷技術

單講“故障診斷”，它是一門新發展的科學，而且越來越受到重視，尤其是在連續生產系統中，故障診斷有著非常重要的意義。按照診斷的方法原理，故障診斷可分為：時頻診斷法、統計診斷法、信息理論分析法及其它人工智慧法（專家系統診斷、人工神經網路診斷等）、模糊診斷、灰色系統理論診斷及集成化診斷（如模糊專家系統故障診斷、神經網路專家系統故障診斷、模糊神經網路診斷等）。

### 3. 狀態預測技術

狀態預測就是根據裝備的運行信息，評估部件當前狀態並預計未來的狀態。其常用的方法有時序模型預測法、灰色模型預測法和演算法預測。而對於預測方法的開發一般有三種基本途徑：物理模型、知識系統和統計模型。在實際應用中，可將三種途徑綜合在一起，形成一種結合了傳統的物理模型和智能分析方法，並能夠處理數字信息和符號信息的混合性故障預測技術，對於實現預測性維修更為有效。

#### 4. 維修決策支持與維修活動

維修決策是從人員、資源、時間、費用、效益等多方面、多角度出發，根據狀態監測、故障診斷和狀態預測的結果進行維修可行性分析，定出維修計劃，確定維修保障資源，給出維修活動的時間、地點、人員和內容。維修決策的制定方法一般有故障樹推理法、數學模型解析法、貝氏（Bayes）網路法（適用於表達和分析不確定和概率性事物）和智能維修決策法等。

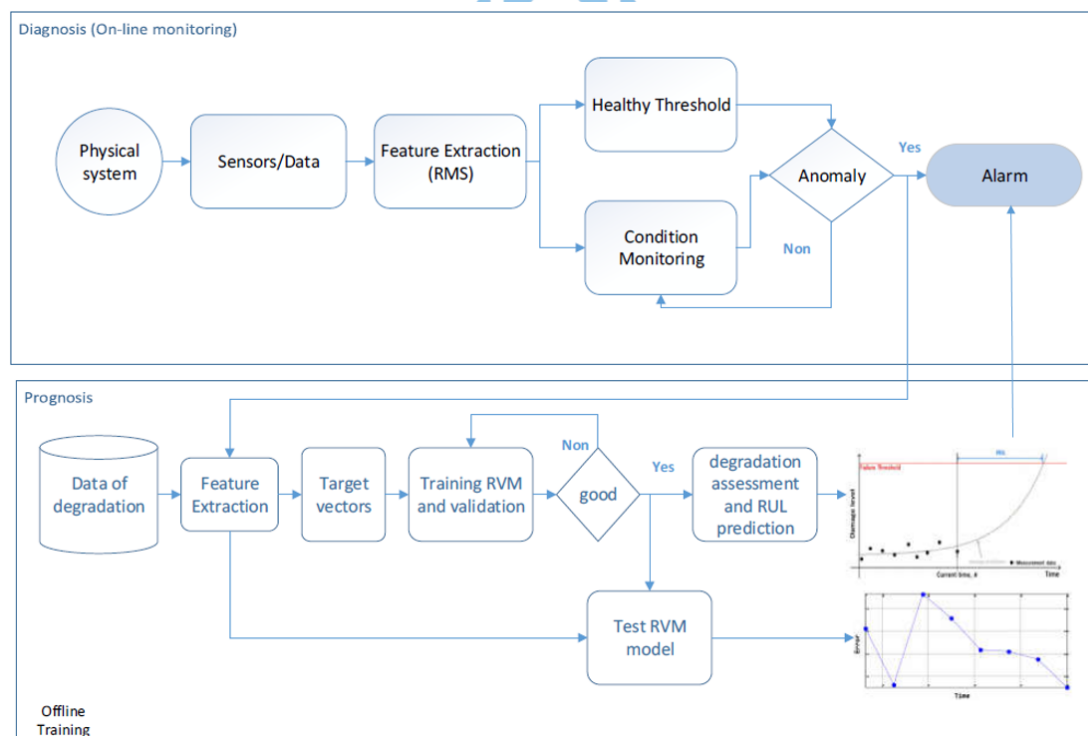


圖 2.5 即時監測和預測流程圖(SVM 為例)

資料來源: Laayouj *et al.* (2016)

## 2.2 預測的方法

預測 (Forecasting) 是預計未來事件的一門藝術，一門科學。它包含採集歷史數據並用某種數學模型來外推與將來。它也可以是對未來的主觀或直覺的預期。而預測的方法通常有高斯回歸、時間序列預測法、灰色模型預測法和演算法，像是丁士展 (2015) 有使用時間序列分析與灰色理論的結合預測貨櫃船新船造價影響，Laayouj *et al.* (2016) 運用 SVM 預測太陽能板剩餘使用壽命，而 Lin *et al.* (2015) 用經典模型的方法，像是 Exponential 和 Power 模型去預測自動車車輪厚度的衰退趨勢。

下表 2.1 是 Lin *et al.* (2015) 用來預測自動車車輪的真實資料，我使用演算法支持向量回歸來和 Lin 所使用的經典模型方法來做比較，如下表 2.2，預測當自動車車輪厚度衰退到 100mm 時的距離，因為衰退到 100mm 時需要做更換。



表 2.1 自動車車輪衰退資料

Distance (km)	Degradation (mm)											
	Bogie I						Bogie II					
	1	2	3	4	5	6	7	8	9	10	11	12
106613	13.08	13.19	12.11	12.12	12.99	13.04	13.02	13.01	11.94	12.01	13.01	13.16
144207	27.11	27.07	23.01	22.86	25.03	25.09	24.09	24.12	23.95	24.06	26.56	26.55
191468	38.95	38.94	39.11	39.06	39.15	39.17	35.95	35.95	35.88	35.93	36.24	36.04
272697	70.6	70.53	69.94	69.87	69.9	69.9	79.7	79.73	79.73	79.74	79.59	79.76
309426	85.05	85.07	85.09	85.12	85.26	85.27	/	/	/	/	82.87	83.77

資料來源: Lin *et al.* (2015)

平均絕對百分比誤差 (Mean Absolute Percent Error, MAPE) 又稱為平均絕對誤差百分比，用以作為預測模式好壞之評估指標。主因為 MAPE 為相對數值，不受測量值與預估值單位與大小之影響，能夠客觀得獲得估計值與評估值間之差異程度，公式如下式 (2.1)，故本研使用 MAPE 來衡量預測的準確度。

$$MAPE = \frac{\sum \left| \frac{\text{實際值}_t - \text{預測值}_t}{\text{實際值}_t} \right| \times 100}{n} \quad (2.1)$$

表 2.2 經典模型和 SVR 的預測比較

MAPE(Exponential)	New(100mm)	MAPE(Power)	New(100mm)	MAPE(SVR)	New(100mm)
6.48%	310604	2.13%	317747	3.87%	305642
13.41%	326885	5.43%	340728	3.85%	319603
14.69%	325647	4.21%	338134	3.98%	321834
14.64%	325601	4.15%	338048	4.03%	321651
12.24%	326348	3.7%	339648	3.39%	320185
12.18%	326374	3.66%	339705	3.38%	320148
6.6%	295324	6.32%	306752	3.47%	270782
6.64%	310604	6.33%	306695	3.49%	270794
9.04%	294824	5.04%	305840	4.04%	267377
8.99%	294876	5.08%	305943	4.07%	267327
15.65%	323782	9.8%	334473	5.28%	322194
15.2%	322609	9.41%	334537	5%	319790

Lewis (1982) 有提出 MAPE 的評估標準，如下表 2.3，SVR 在各組表現都有不錯的成效，MAPE 都有在 10% 以下，是個高準確的預測。

表 2.3 MAPE 對模型的評估

MAPE (%)	Evaluation
$\text{MAPE} \leq 10\%$	High Accuracy Forecasting
$10\% \leq \text{MAPE} \leq 20\%$	Good Forecasting
$20\% \leq \text{MAPE} \leq 50\%$	Reasonable Forecasting
$\text{MAPE} > 50\%$	Inaccuracy Forecasting

資料來源：Lewis (1982)

## 第三章 研究方法

本研究主要是應用支持向量回歸 (SVR) 、滾動式預測 (Rolling Forecate) 對 Ball Bearings 和太陽能板進行預測衰退趨勢，藉由預測後結果計算出 RUL 並做出維修決策；故本章為說明支持向量回歸和滾動式預測是如何進行預測、計算加以介紹。

### 3.1 支持向量回歸

支持向量機 (SVM) 是一種用來做分類 (Classification) 或用來處理回歸 (Regression) 的問題，而用來處理回歸問題稱為 SVR。支持向量回歸又針對處理不同問題分為兩種類型，第一類為線性向量支持回歸，第二類是非線性支持向量回歸。

#### 3.1.1 線性向量支持回歸

Smola and Schölkopf (2004) 有提到 SVR 基本想法，給定一組訓練資料 (Training Data) 可表示為  $(x_1, y_1), \dots, (x_i, y_i) \in \mathbb{R}^d \times \mathbb{R}$ ，其中  $x$  表示為輸入值代表資料的屬性 (Attribute)， $y$  表示為屬性的對應值。我們令方程式  $f(x) = w \cdot x + b$ ， $w \in \mathbb{R}^d$ ， $b \in \mathbb{R}$ ，若每個  $f(x_i)$  和  $y_i$  差的值都能很小就可以用來準確的預測  $y$ ，故我們找出最合適的  $w$ 。要求解出這個  $w$ ，我們可以視為求解凸函數最佳化問題：


$$\begin{aligned} & \text{Minimize} \quad \frac{1}{2} \|w\|^2 \\ & \text{Subject to} \quad \begin{cases} y_i - (w \cdot x_i) + b \leq \varepsilon \\ (w \cdot x_i) + b - y_i \leq \varepsilon \end{cases} \end{aligned} \quad (3.1)$$

其中  $\varepsilon > 0$ ，用來表 SVR 預測的值與實際值的差距。若在合理的  $\varepsilon$  能解出式 (3.1) 的值，我們稱為 Feasible。然而在大多狀況下資料都存在著雜訊 (Noise)、離群值 (Outlier) 和誤差等各種因素影響，造成不會有 Feasible 的情況。因此 Vapnik (1995) 就有提出損失函數 (Loss Function) 和懲罰係數 (Penalty Parameter) 來解決：

$$\begin{aligned}
& \text{Minimize} \quad \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m (\xi_i + \xi_i^*) \\
& \text{Subject to} \quad \begin{cases} y_i - (w \cdot x_i) + b \leq \varepsilon + \xi_i \\ (w \cdot x_i) + b - y_i \leq \varepsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases} \quad (3.2)
\end{aligned}$$

懲罰係數用於解決雜訊或離群值所產生的問題，用來調整訓練模型 (Training Model) 是否有過度或不適資料，以  $C$  表示。鬆動變數 (Slack Variable) 可以將沒有包含在函式中的資料表示出來，每一組訓練資料都有其對應的  $\xi_i$  及  $\xi_i^*$ ，用來決定該組訓練資料是否會落於  $\varepsilon$  的範圍之外。

像這樣的問題可以用 Lagrange Multiplier 來處理，我們將式 (3.2) 寫成 Lagrange Function:

$$\begin{aligned}
L = & \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m (\xi_i + \xi_i^*) - \sum_{i=1}^m (\eta_i \xi_i + \eta_i^* \xi_i^*) \\
& - \sum_{i=1}^m \alpha_i (\varepsilon + \xi_i - y_i - w \cdot x_i + b) \\
& - \sum_{i=1}^m \alpha_i^* (\varepsilon + \xi_i^* - y_i - w \cdot x_i + b) \quad (3.3)
\end{aligned}$$


這個問題是一個 Convex Optimization Problem，因此可用 Lagrange Dual Optimization Problem 來解決，因此 Min 和 Max 可以互換。我們先考 Min 的情形，求極值及所有變數偏微分為零之處：

$$\frac{\partial L}{\partial b} = \sum_{i=1}^m (\alpha_i^* - \alpha_i) = 0 \quad (3.4)$$

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^m (\alpha_i - \alpha_i^*) x_i = 0 \quad (3.5)$$

$$\frac{\partial L}{\partial \xi_i^{(*)}} = C - \eta_i^{(*)} - \alpha_i^{(*)} = 0 \quad (3.6)$$



再將式(3.4)、式(3.5)和式(3.6)代入式(3.3)中並改寫成：

$$\begin{aligned} \text{Maximize } & -\frac{1}{2} \sum_{i,j=1}^m (\alpha_i - \alpha_i^*) (\alpha_j - \alpha_j^*) x_i \cdot x_j - \varepsilon \sum_{i=1}^m (\alpha_i + \alpha_i^*) + \sum_{i=1}^m y_i (\alpha_i - \alpha_i^*) \\ \text{Subject to } & \sum_{i=1}^m (\alpha_i - \alpha_i^*) = 0 \text{ and } \alpha_i, \alpha_i^* \in [0, C] \end{aligned} \quad (3.7)$$

再依據 Fletcher (1987) 所提到的 Karush Kuhn-Tucker (KKT) 理論，代入 w 將可以得到 b，最後可以得到訓練資料所產生的回歸方程式(3.8)

$$f(x) = \sum_{i=1}^m (\alpha_i - \alpha_i^*) (x_i \cdot x_j) + b \quad (3.8)$$

### 3.1.2 非線性向量支持回歸

上述的回歸函式是當資料為線性時的表示方式，但現實生活中的資料並非都為線性，要解決這方面的問題 Vapnik (1995) 和 Schölkopf (2000) 發現當資料為非線性時，可以先透過核心運算模式將資料特徵轉換到另一個較高維度的特徵空間，再進行資料的預測，可以獲得更好的效果。由圖 3.1 可以看出，原始資料在原本空間為非線性的函式，但經由轉換高維度的空間，變成一個線性的函式，進而方便運算。




圖 3.1 原始資料從原始空間透過轉換到較高維度的空間

$(x_i \cdot x_j)$ 可改寫成一 Kernel Function  $k(x_i \cdot x_j)$ ，令 $k(x_i \cdot x_j) = (\phi(x_i) \cdot \phi(x_j))$ ，其中 $\phi(x_i)$ 、 $\phi(x_j)$ 為可將某維度資料投影到其他維度資料的對應。因此只要利用核心函數計算出資料在特徵空間的值，就能解決非線性所產生的困難。

SVR 一般常用之核心函式有三種 (Gunn, 1998)，線性 (Linear)、多項式 (Polynomial)、放射函數 (Radial Basis Function; RBF)。

$$\text{線性核心函數： } k(x_i, x_j) = x_i \cdot x_j^T \quad (3.9)$$

$$\text{多項式核心函數： } k(x_i, x_j) = (1 + x_i \cdot x_j)^d \quad (3.10)$$

$$\text{放射核心函式： } k(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (3.11)$$

每個核心函式都有自己的參數設定，可能因資料性質不同而設定不同，因此使用者可以針對不同核心、資料做調整。本研究資料個案一使用放射核心函式，個案二使用線性核心函式。



### 3.2 參數的選擇方法

SVR model 在訓練時，有兩個重要參數需要設定，Cost 和 Gamma，其中 Cost 為上述提到的懲罰係數，而 Gamma 是 Kernel 內部的一個參數。這兩個參數的決定對訓練結果影響重大，但目前並無公式可以來決定 Cost 和 Gamma 該設為多少，不同案例會有不同適用的 Cost 和 Gamma，所以我們只能一個一個試。

本研究是使用 R 語言來分析資料，其中的 e1071 套件有個功能 (Meyer *et al.*, 2017)，能設定 Cost 和 Gamma 的範圍，在彼此的範圍內找到最佳的組合。例如個案二中，我們要找出最適合太陽能板衰退資料的參數，就會先打上這段指令 `tune.svm(Pmax~., data = Lset, kernel="linear", gamma = seq(0.5, 5, by = 0.5), cost = seq(1, 100, by = 10))`，意思就是在 Cost = 1 到 Cost = 100 每個間格 10 和 Gamma = 0.5 到 Gamma = 5 每個間格 0.5，在兩參數範圍之中尋找最佳組合，也就是在 100 個組合中找到錯誤率最低的組合就為最佳參數組合。

### 3.3 滾動式預測

隨著時間推進，不斷獲得最新的資訊去修正預測，便可以提升預測準確度，這種概念便是滾動式預測。Stretch (2012) 有提到滾動式預測的概念，如圖 3.2。

#### A five-quarter rolling forecast

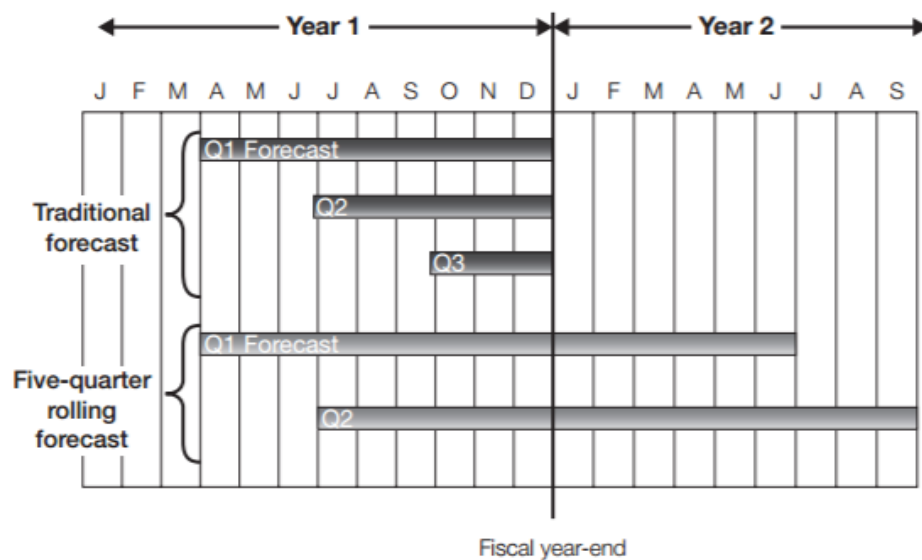


圖 3.2 傳統預測合滾動式預測比較圖

資料來源：Stretch (2012)

我們可以看到圖 3.2，傳統的預測方法，Q1 將整年度預測後就結束，但滾動式預測是 Q1 整年度預測完後，Q2 會接續的向後預測，這樣就能隨著時間推進，預測獲得更新的資訊。

張怡筠 (2006) 也有以企業需求為例，如圖 3.3。企業通常都會對未來的需求進行預測，以作為未來營運的方針。如果當市場需求發生變動，例如當有競爭者出現，造成需求下降。而企業在下一個規劃週期點時，根據目前市場的狀況對之後的預測進行調整，以符合市場的變化。

當競爭者出現，造成需求下降

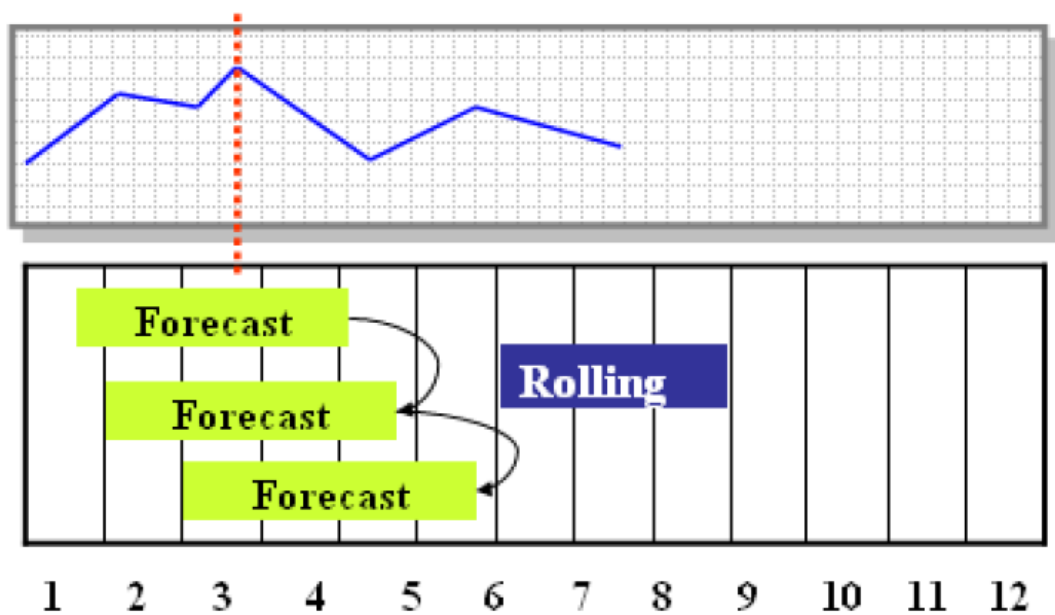


圖 3.3 滾動式預測概念圖



## 第四章 案例分析

### 4.1 個案 1-Ball Bearings Data

#### Ball Bearings 資料介紹

Ball Bearings 資料來自 IEEE Reliability Society 和 FEMTO-ST Institute 所舉辦的 IEEE PHM 2012 Data Challenge。PHM Challenge Datasets 可自 FEMTO-ST Institute 下載。資料是在實驗室內加速衰退測試所收集的，在這實驗中 Ball Bearings 的衰退只需要幾小時，實驗平台如圖 4.1。在測試過程中由感測器即時收集 Ball Bearings 的溫度和振動訊號，直到 Ball Bearings 的振動訊號的振幅超過 20g 並且失效。從圖 4.2 可看到正常和衰退的 Ball Bearings 和振動訊號的收集，當振幅超過 20g 後會有產生很大的振動變化。




圖 4.1 實驗平台圖

資料來源：IEEE PHM 2012 Prognostic Challenge




圖 4.2 Ball Bearings 衰退前後和衰退過程振幅圖

資料來源：IEEE PHM 2012 Prognostic Challenge

資料在三種不同環境下加速衰退測試：

第一種狀況：1800 rpm 和 4000 N；

第二種狀況：1650 rpm 和 4200 N；

第三種狀況：1500 rpm 和 5000 N；

三種狀況中，Learning set 共有 6 組，Test set 共有 13 組，詳細如表 4.1。

表 4.1 Datasets of IEEE 2012 PHM Prognostic Challenge

Datasets	Conditions 1	Conditions 2	Conditions 3
Learning set	Bearing1_1	Bearing2_1	Bearing3_1
	Bearing1_2	Bearing2_2	Bearing3_2
Test set	Bearing1_3	Bearing2_3	Bearing3_3
	Bearing1_4	Bearing2_4	
	Bearing1_5	Bearing2_5	
	Bearing1_6	Bearing2_6	
	Bearing1_7	Bearing2_7	

資料來源：IEEE PHM 2012 Prognostic Challenge

本研究選擇第一種狀況，感應器以 256Hz 收集垂直和水平振動資料，每份檔案收集 10 秒，所以有 2560 個點，我們將資料取絕對值再將最高的五個平均，平均是為了減少 Noise 所帶來的影響，依序從 2803 個檔案取出，如圖 4.3。




圖 4.3 Bearing1\_1 2000# Horizontal 2560 個點取絕對值最大五個點

資料來源：Sutrisno *et al.* (2012)




圖 4.4 Bearing1\_1 衰退資料




圖 4.5 Bearing1\_4 衰退資料

溫度感應器以 10Hz 收集資料，將資料每十秒平均，再調整成和垂直振動資料長度一樣，如圖 4.6、圖 4.7，我們可以看到溫度隨著時間持續上升。




圖 4.6 Bearing1\_1 溫度資料






圖 4.7 Bearing1\_4 溫度資料

### 資料分析結果

我們使用 Bearing1\_1 衰退資料來訓練 SVR Model 再使用 Bearing1\_4 衰退資料測試 SVR Model 效果。分為兩種模型進行測試，第一種使用時間去預測水平振動、第二種運用時間和溫度去預測水平振動。

#### a. SVR-Model-1 (Input: Time, Output: Horizontal )

表 4.2 Learning Bearing1\_1, Test Bearing 1\_4 (未加入溫度)

Learning-Horizontal-MAPE	Test-Horizontal-MAPE
13.07%	18.6%




圖 4.8 Bearing1\_1 (未入溫度)衰退預測




圖 4.9 Bearing1\_4 (未入溫度)衰退預測

**b. SVR-Model-2 (Input: Time and Temperature, Output: Horizontal)**

表 4.3 Learning Bearing1\_1 , Test Bearing 1\_4 (加入溫度)

Learning-Horizontal-MAPE	Test-Horizontal-MAPE
12.75%	15.29%




圖 4.10 Bearing1\_1 (加入溫度)衰退預測




圖 4.11 Bearing1\_4 (加入溫度)衰退預測

由表 4.2 和表 4.3 可知道加入溫度作為解釋變數 Model Fitting 的效果變得更好。而圖 4.10 和圖 4.11 可了解 SVR 在長區間和資料衰退趨勢差異很大的預測效果不佳。

再來我們要加入 Sutrisno *et al.* (2012) 在 IEEE Conference 內所使用的 Method 3，其中資料 Bearing1\_1 為 Learning Set 而 Bearing1\_3、Bearing1\_4 為 Test set。

首先可以看到圖 4.12 中，Bearing1\_1 在第 13000 秒時，因為 Vertical 的訊號超過 20g 而發出第一次警告，而在第 27660 秒時，因為 Horizontal 的訊號超過 20g 而發出第二次警告，而第二次警告後到失效的時間為 380 秒。再來有兩步驟分析 Test 資料，第一步驟是利用 Bearing1\_1 計算出異常區間，就是當第一次警告到發出第二次警告的時間，並計算出異常區間衰退速率，第二步驟為預測第二次警告後多久時間 Bearing 會失效，並計算出 Bearing 的 RUL。




圖 4.12 Bearing1\_1 衰退趨勢和異常圖

首先我們看到圖 4.13 中，使用 SVR 預測從發出第一次警告到第二次警告的衰退趨勢，知道第一次警告到第二次警告的 Horizontal 值相差 5.766g，我們將他設為一個閾值，並算出異常區間衰退率，之後運用在 Test 資料中。

$$\text{AnomalyRatio} = \frac{380 \text{ s}}{27660 \text{ s} - 13000 \text{ s}} = 0.02592$$




圖 4.13 Bearing1\_1 第一次警告到第二次警告趨勢圖

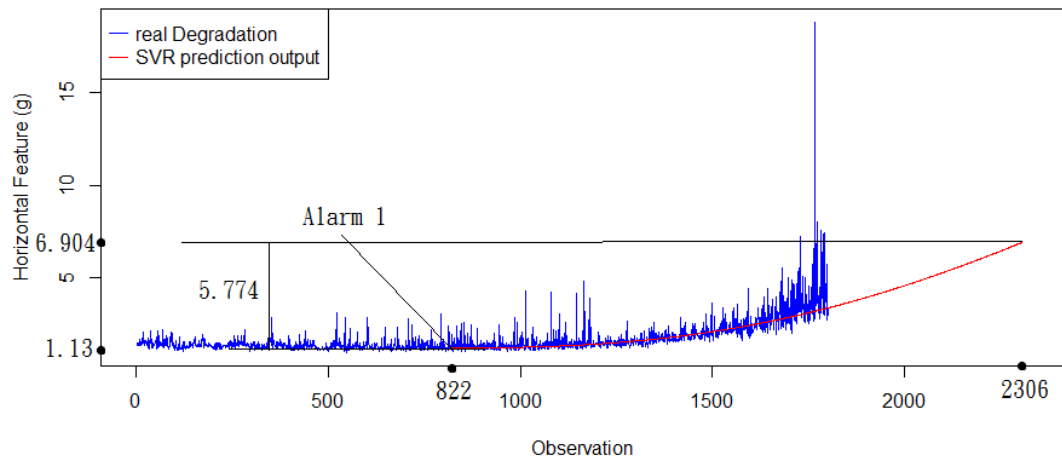


圖 4.14 Bearing1\_3 第一次警告到 Horizontal 超過閾值趨勢圖

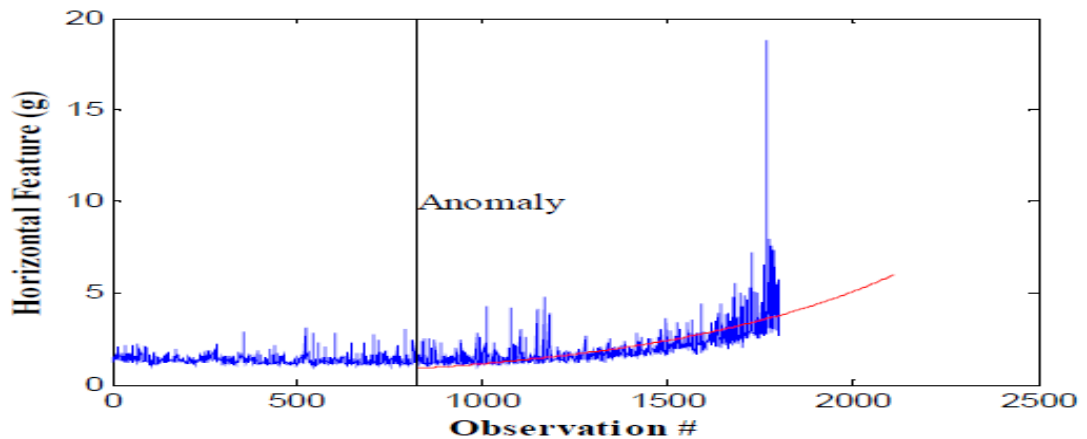


圖 4.15 Bearing1\_3 實際衰退與 Exponential 預測衰退趨勢圖

資料來源：Sutrisno *et al.* (2012)

圖 4.14 是由 SVR 預測出的衰退趨勢，可以知道 Bearing1\_3 在第 8220 秒時發出第一次警告，此第一次警告是使用 Sutrisno *et al.* (2012) 在 Method 3 所使用的時間點，如圖 4.15。我們利用 Bearing1\_1 算出的閾值知道，Bearing1\_3 在第 23060 秒時 Horizontal 的值與第一次警告的 Horizontal 值相差超過閾值 5.766 g，再將此時間差算出第二次發出警告到失效的時間點。

發出第二次警告到結束的區間 =  $0.02592 \times$  第一次發出警告到第二次警告的區間

$$= 0.02592 \times 14840 = 384.65 \approx 385 \text{ s}$$

再算出第一次警告到失效的時間。

$$\text{第一次警告到失效的時間} = 14840 + 385 = 15225 \text{ s}$$

Bearing1\_3 在第一次警告後到最後紀錄的存活時間為 9800 秒，故我們預測最後剩餘使用壽命為下計算式。

$$\text{RUL of Bearing1\_3} = 15225 - 9800 = 5425 \text{ s}$$




圖 4.16 Bearing1\_4 第一次警告到 Horizontal 超過閾值趨勢圖

圖 4.16 是由 SVR 預測出的衰退趨勢，可以看到 Bearing1\_4 在第 11260 秒時發出第一次警告，因為此時 Vertical 訊號超過 20g，在第 11610 秒時超過閾值，我們再使用一樣的方法算出 RUL。

發出第二次警告到結束的區間 =  $0.02592 \times$  第一次發出警告到第二次警告的區間

$$= 0.02592 \times 460 = 11.92 \approx 12 \text{ s}$$

再算出第一次警告到失效的時間。

第一次警告到失效的時間 =  $460 + 12 = 472$  s

Bearing1\_4 在第一次警告後到最後紀錄的存活時間為 140 秒，故我們預測最後剩餘使用壽命為下計算式。

RUL of Bearing1\_3 =  $472 - 140 = 332$  s

Sutrisno *et al.* (2012) 在 IEEE conference 內所使用的 Method 3 是利用 Exponential 去 Fit 資料，而計算出 Bearing1\_3 的 RUL 為 3604 秒和 Bearing1\_4 的 RUL 為 67 秒。

表 4.4 真實 RUL 時間

Test set	Actual RUL
Bearing1_3	5730 s
Bearing1_4	339 s
Bearing1_5	1610 s
Bearing1_6	1460 s
Bearing1_7	7570 s
Bearing2_3	7530 s
Bearing2_4	1390 s
Bearing2_5	3090 s
Bearing2_6	1290 s
Bearing2_7	580 s
Bearing3_3	820 s

資料來源：IEEE PHM 2012 Prognostic Challenge

由表 4.4 可知 Bearing1\_3 的真實 RUL 為 5730 秒，Bearing1\_4 的真實 RUL 為 339 秒。我們在看表 4.5，本研究使用的 SVR 預測出來的效果比 Sutrisno *et al.* (2012) 在 Method 3 所使用 Exponential 預測的效果來的好，RUL 錯誤率都比較低。

表 4.5 預測 RUL 的錯誤率

Bearing	Exponential RUL Error	SVR RUL Error
Bearing1_3	37 %	5.32 %
Bearing1_4	80 %	2.06 %

## 4.2 個案 2-PV data

### 資料介紹

Laayouj *et al.* (2016) 使用 SVM 預測太陽能板衰退趨勢，預測流程如圖 2.5。由電壓衰退作為警告，當衰退到一定值發出警告，並開始預測衰退趨勢算出 RUL。其中使用和太陽能板衰退最相關的電壓 (V) 和最大功率 (Pmax) 來當作計算 RUL 的標準，故本研究參照 Laayouj *et al.* (2016) 文章中衰退的趨勢，模擬出 120 個月電壓和最大功率。



### 資料分析結果

本小節分為兩種不同的 SVR 預測方法，第一種方法我們分成兩階段：

第一階段：使用電壓的資料去找出發出警告的時間。

我們判斷太陽能板是否有不正常情況發生的依據為計算 RMS (Root Mean Squar) 值，藉由 Voc<sub>r</sub> (Open-Circuit Voltage Reference) 和 Voc<sub>m</sub> (Open-Circuit Voltage Measured) 的差算出，公式如下式 (12)。其中 Voc<sub>r</sub> 為一開始太陽能板狀態的電壓值。

$$VOC_{RMS} = \left( \frac{1}{n} \sum_{t=1}^n (V_{ocr}(t) - V_{ocm}(m))^2 \right)^{\frac{1}{2}} \quad (4.1)$$

圖 4.17 和圖 4.18 為電壓的衰退和 RMS 趨勢圖，當 RMS 超過 1 時會發出警告，並進入第二階段。






圖 4.17 真實電壓衰退趨勢




圖 4.18 RMS 趨勢

第二階段：預測功率衰退趨勢，算出 RUL 並決定維修方案。

我們使用兩種不同的閾值去決定維修方案。方案一：  $P_{\max} = 85W$ ，檢查和維修重要零件，方案二：  $P_{\max} = 83.5W$ ，需去替換因衰退造成功率降低的零件。

RUL 的公式為下式 (13)：

$$RUL = T_p - T_r \quad (4.2)$$

其中  $T_p$  為  $P_{\max}$  到達閾值所對應的時間， $T_r$  為發出警告後所對應的時間。

第二種方法我們使用滾動式預測的概念先取 1 到 43 個月做為 SVR model 的學習資料，再預測後 6 個月衰退趨勢，之後再捨棄前六個月，加入新的六個月資料，所以為 7 到 49 個月做為 SVR model 的學習資料，若有更佳的參數則修改，

再預測後 6 個月衰退趨勢，以此類推，直到我們所設定的閾值，滾動式預測的概念圖如圖 4.19。閾值的設定和 Method 1 相同。

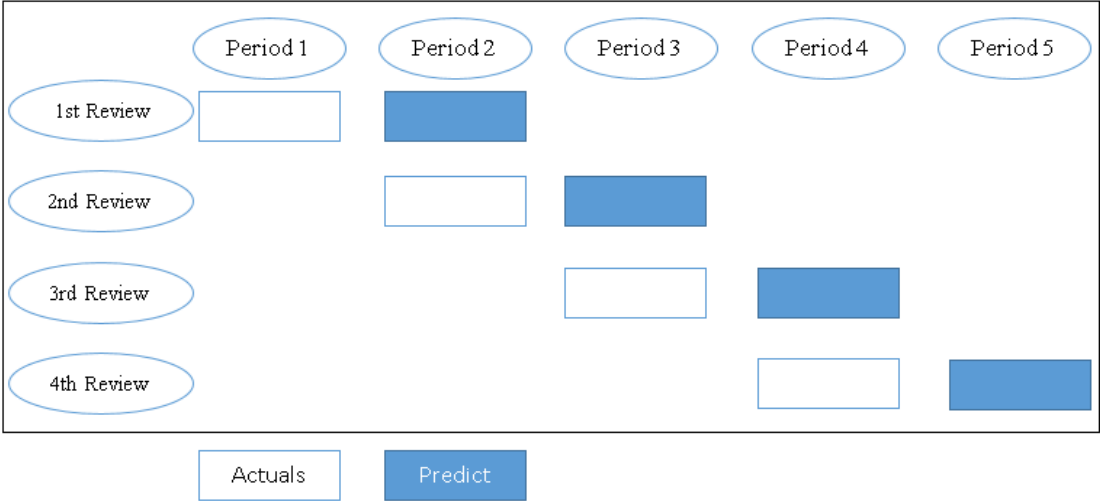


圖 4.19 滾動式預測作法



**A. Method-1**

**43-114 months and predict 44-120 months**

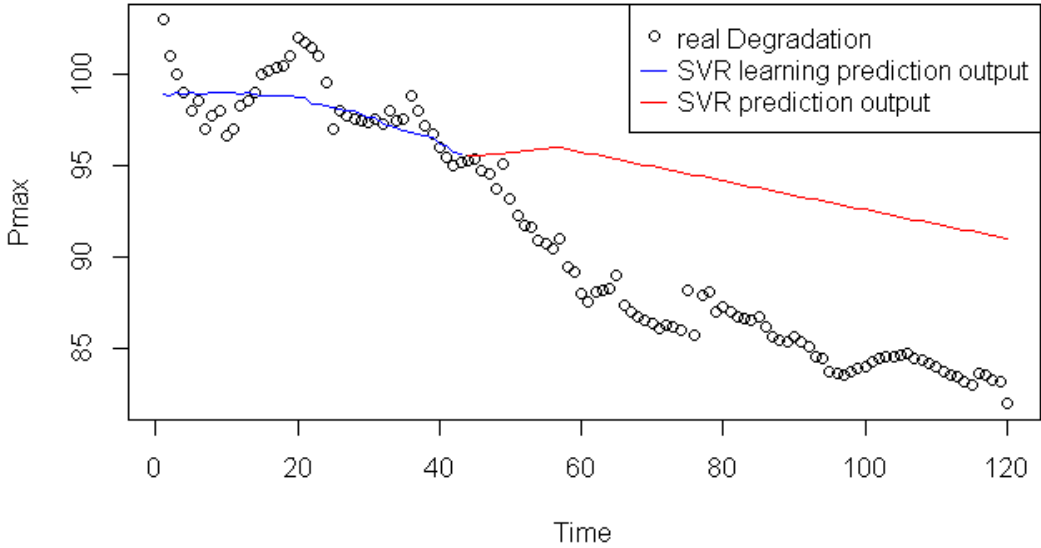


圖 4.20 實際衰退和 SVR 預測結果

由圖 4.11、圖 4.20 可知 SVR 在長段時間預測是不準確的，所以我們再模擬

一組太陽能板衰退趨勢，讓 SVR model 學習整組衰退趨勢，預測結果如圖 4.16。

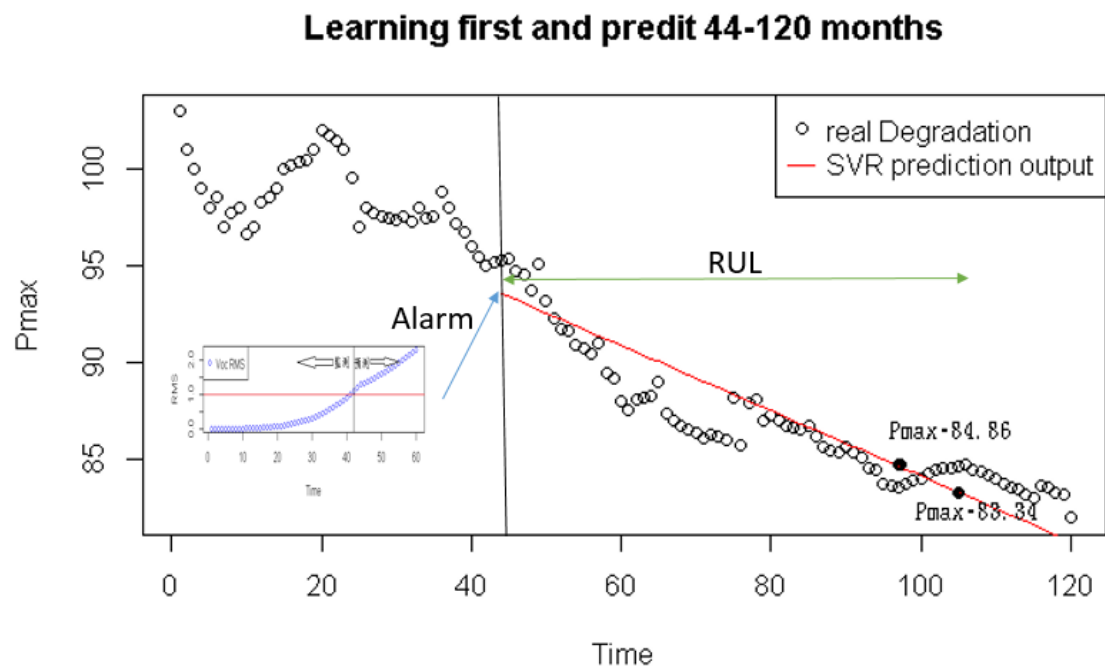


圖 4.21 實際衰退與 SVR 先學習後預測結果

我們可以看到圖 4.21 的預測結果效果不錯，RUL 為 62 個月，在第 96 個月時需實施方案一，第 105 個月時需要實行方案二替換物件。在現實中很多情況是沒有歷史資料的或是同樣的物件衰退的趨勢很不一樣，此時預測就容易發生不準確的問題，故 Method 2 使用滾動式預測法解決以上問題。

## B. Method-2

1-43 months and predict 44-49 months

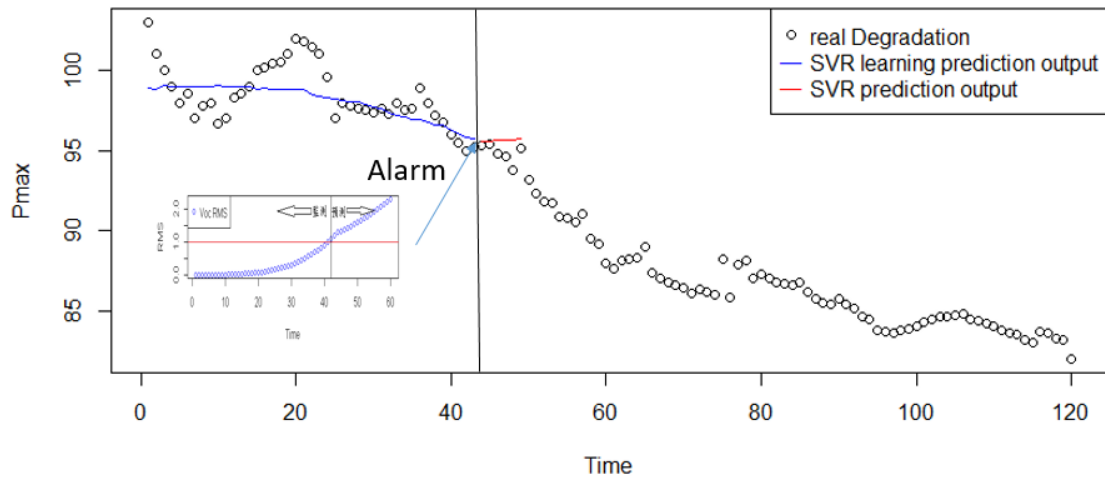


圖 4.22 實際衰退和 SVR 預測第 44 月到第 49 月結果

當第 43 個月 RSM 超過 1，此時發出警告，進入第二階段衰退預測，參設定為  $\text{Gamma} = 0.5$  和  $\text{Cost} = 1$ ， $\text{MAPE} = 3.35\%$ 。

7-49 months and predict 50-55 months




圖 4.23 實際衰退和 SVR 預測第 50 月到第 55 月結果

由於近幾個月的趨勢為向上，所以後 6 個的預測會有向上的趨勢，此時參數設定為  $\text{Gamma} = 0.5$  和  $\text{Cost} = 61$ ， $\text{MAPE} = 6.56\%$ 。




圖 4.24 實際衰退和 SVR 預測第 56 月到第 61 月結果

近幾個月的衰退穩定，開始向下衰退的趨勢，此時參數的設定  $\text{Gamma} = 0.5$  和  $\text{Cost} = 11$ ， $\text{MAPE} = 0.84\%$ 。




圖 4.25 實際衰退和 SVR 預測第 62 月到第 67 月結果

預測持續有向下衰退趨勢，此時參數的設定為  $\text{Gamma} = 0.5$  和  $\text{Cost} = 11$ ， $\text{MAPE} = 0.44\%$ 。




圖 4.26 實際衰退和 SVR 預測第 68 月到第 73 月結果

預測持續有向下衰退趨勢，此時參數的設定為  $\text{Gamma} = 0.5$  和  $\text{Cost} = 21$ ， $\text{MAPE} = 0.25\%$ 。




圖 4.27 實際衰退和 SVR 預測第 74 月到第 79 月結果

由圖 4.27 可知，在第 73 個月時會發出警告，第 74 個月時  $P_{\max}$  達到閾值 1，故需實行方案一，需檢查和維修重要零件，此時參數的設定  $\text{Gamma} = 0.5$  和  $\text{Cost} = 21$ ， $\text{MAPE} = 3.06\%$ 。




圖 4.28 實際衰退和 SVR 預測第 80 月到第 85 月結果

由圖 4.28 可知，在第 79 個月時會發出警告，第 85 個月時 Pmax 達到閾值 2，需實行方案二，需去替換因衰退造成功率降低的零件，此時 RUL 為 6 個月此時參數的設定  $\text{Gamma} = 0.5$  和  $\text{Cost} = 11$ ， $\text{MAPE} = 0.33\%$ 。

表 4.6 Method 1 和 Method 2 的參數和 MAPE 比較表

Predict data	Method 1		Method 2	
	Parameters	MAPE	Parameters	MAPE
44-120	$G=0.5$ 、 $C=1$	1.57%	-	-
44-49	-	-	$G=0.5$ 、 $C=1$	3.35 %
50-55	-	-	$G=5$ 、 $C=61$	6.56%
56-61	-	-	$G=0.5$ 、 $C=11$	0.84%
62-67	-	-	$G=0.5$ 、 $C=11$	0.44%
68-73	-	-	$G=0.5$ 、 $C=21$	0.25%
74-79	-	-	$G=0.5$ 、 $C=21$	3.06%
80-85	-	-	$G=0.5$ 、 $C=11$	0.33%

滾動式預測是屬於一種動態的預測方法。預測不可能完全跟未來實際狀況完全符合，而預測的時間區段越長，預測值越不準確。所以隨著時間推進，用新蒐集到的資訊去修正預測，能提高預測的準確度。故我們可以用滾動式預測去解決長時段和突發性衰退造成預測不準確的情形，由圖 4.21 和圖 4.28 能看出，若超過第 85 個月沒替換零件，太陽能板可能會造成突發性的停擺，而使用滾動式預測就能較接近真實的衰退狀況，及時避免無預警的停擺。





## 第五章 結論與建議

Ball Bearing 對機台來說是重要的零件，而太陽能板是精密且昂貴的設施，若發生無預警的失效，可能會造成巨大的損失，而太常保養就需要花費較高的成本，因此能發現系統不正常點並找到最佳的維修時機是很重要的。我們可以從第四章個案一看到，感測器每 10 秒收集 2560 筆資料，一小時就能收集幾百萬筆資料，而本研究利用此監測資料找出不正常點，並運用 SVR 算出 RUL，算出的 RUL 與真實的 RUL 也很相近，效果更是比 Sutrisno *et al.* (2012) 所使用的 Exponential 模型效果來的好，只要預測的夠準確，就能在正確的時間點維修，大幅降低維修成本；在個案二中，我們可以看到在長區間的預測，通常會有不準確的情況發生，Method 1 需要靠歷史失效資料來增加準確度，而現實生活當中，物件失效的資料不易取得，故 Method 2 中使用的滾動式預測，能隨著時間推進更新模型適合度，讓預測出來的值更貼近真實情況。

未來可以將本研究方法運用在其他有衰退趨勢的物件上使用，並加入其他預測方法或演算法，來精進預測 RUL 的準確度。若真實案例有成本可以加入，就能與傳統的矯正性維修和預防性維修做成本比較。

## 參考文獻

### 中文文獻

- 丁士展、李泓逸、呂亦宸。貨櫃船新船造價影響變數與預測模式之研究 - 整合時間序列分析與灰色理論。航運季刊，24，65-85。(2015)。
- 張怡筠。CPFR 中滾動式預測的關鍵因子探討。國立清華大學資訊系統與應用研究所碩士論文，新竹 (2002)。
- 辜樹仁。不賣飛機引擎，改賣「飛機時數」。天下雜誌，601，108-111 (2016)。
- 顧尚芳。生產系統中利用製程不良率評估設備預防維護之研究。中原大學工業工程研究所碩士論文，桃園 (2003)。

### 英文文獻

- Budai-Balke, B., *Operations Research Models for Scheduling Railway Infrastructure*, PhD thesis, Erasmus University Rotterdam, Netherlands (2009).
- Francis, E.G., *Systems Reliability and Risk Analysis*, Springer Netherlands (1988).
- Fletcher, R., *Practical Methods of Optimization, 2nd Edition*, Wiley (1987).
- Gunn, S.R., *Support Vector Machines for Classification and Regression*, Technical Report, Image speech and Intelligent Systems Research Group, University of Southampton (1998).
- Laayouj, N., J. Hicham and M. A. El Hail, “Photovoltaic Module Health Monitoring and Degradation Assessment,” *Proceedings of the 2016 3rd Conference on Control and Fault-Tolerant Systems*, 7-9 (2016).
- Lewis, C.D., *Industrial and Business Forecasting Methods*, Butterworths, London (1982).

- Lin, J., J. Pulido and M. Asplund., “Reliability Analysis for Preventive Maintenance Based on Classical and Bayesian Semi-Parametric Degradation Approaches Using Locomotive Wheel-Sets as a Case Study,” *Reliability Engineering and System Safety*, **134**, 143-156 (2015).
- Meyer, D., E. Dimitriadou., K. Hornik., A. Weingessel., F. Leisch., C. Chih Chung. and Lin. Chih Chen., “Package e1071,” Repository CRAN (2017).
- Schölkopf, B.,” Statistical Learning and Kernel Methods,” Technical Report, Microsoft Research, Cambridge (2000).
- Smola, A.J. and B. Schölkopf., “A Tutorial on Support Vector Regression,” *Statistics and Computing*, **14**, 199-222 (2004).
- Stretch, J., *Managing with Rolling Forecasts*, Stretch Publishing (2012).
- Sutrisno, E., H. Oh., A. Vasan and M. Pecht., “Estimation of Remaining Useful Life of Ball Bearings,” *Prognostics and Health Management (PHM), 2012 IEEE Conference*, 1-7 (2012).
- Vapnik. V., *The Nature of Statistical Learning Theory*, Springer-Verlag (1995).

## 網路文獻

- Dataconomy 。 網址： <http://dataconomy.com/2015/04/predictive-maintenance-big-data-on-rails/> 。 上網日期：2017-03-22 (2014) 。
- FEMTO-ST Institute。 網址：<http://www.femto-st.fr/>。 上網日期：2017-04-20 (2012) 。
- IEEE PHM 2012 Prognostic Challenge 。 網址： <http://www.femto-st.fr/en/Research-departments/AS2M/Research-groups/PHM/IEEE-PHM-2012-Data-challenge.php> 。 上網日期 2017-04-20 (2012) 。
- MBA 智庫百科。 網址： <http://wiki.mbalib.com/zh-tw/> 。 上網日期：2017-03-22 (2016) 。

## 附錄

### 附錄 A. 個案 1 中讀取資料 Code

```
install.packages("stringr")

library(stringr)

setwd("C:/Users/user/Documents/acc1 ")

dataPath="C:/Users/user/Documents/acc1/acc_"

Horizontal <-c()

Vertical <-c()

for (i in 1:2803){

  name<-str_pad(i,5,pad="0")

  data <-

read.table(file=paste(paste(dataPath,name,sep=""),".csv",sep=""),header=FALSE,sep="

"),

  a=abs(data[,5])

  b=abs(data[,6])

  c=t(a)

  d=t(b)

  Horder=sort(c)

  Vorder=sort(d)

  e=Horder[2560]+Horder[2559]+Horder[2558]+Horder[2557]+Horder[2556]

  f=Vorder[2560]+Vorder[2559]+Vorder[2558]+Vorder[2557]+Vorder[2556]

  Horizontal[i] <- e/5

  Vertical[i] <- f/5
```

```
}
```

```
Trend=cbind(Horizontal,Vertical)
```

```
write.table(Trend,file = "Trend.csv",sep = ",")
```

## 附錄 B. 個案 1 中取出溫度資料 Code

```
install.packages("stringr")
```

```
library(stringr)
```

```
setwd("C:/Users/user/Documents/acc1 ")
```

```
dataPath="C:/Users/user/Documents/acc1/temp_"
```

```
Temperture <-c()
```

```
for (i in 1:187){
```

```
  name<-str_pad(i,5,pad="0")
```

```
  data <-
```



```
read.table(file=paste(paste(dataPath,name ,sep=""),".csv",sep=""),header=FALSE,sep="
,")
```

```
  a=data.frame(data[,5])
```

```
  b=data.frame(a[32:531,])
```

```
  for (j in 1:5){
```

```
    Temperture[(6*i-6)+1]=mean(a[1:31,])
```

```
    Temperture[(6*i-6)+j+1]=mean(b[((100*j)-99):(100*j),])
```

```
  }
```

```
}
```

```
name<-str_pad(188,5,pad="0")
```

```
data <-
```

```

read.table(file=paste(paste(dataPath,name ,sep=""),".csv",sep=""),header=FALSE,sep="
,")

w=data.frame(data[,5])

e=data.frame(w[32:531,])

for (j in 1:4){

  Temperture[(6*188-6)+1]=mean(w[1:31,])

  Temperture[(6*188-6)+j+1]=mean(e[((100*j)-99):(100*j),])

  Temperture[(6*188-6)+6]=mean(w[522:527,])

}

write.table(Temperture,file = "Temperture.csv",sep = ",",row.names = FALSE)

```

## 附錄 C. 個案 1 中分析 Model Fitting 的 Code

```

library(e1071)

a=read.table(file = "Learning1.csv",header = TRUE,sep = ",")

b=read.table(file = "Test1.csv",header = TRUE,sep = ",")

z=a[,-4]

x=a[,-3]

w=b[,-4]

y=b[,-3]

####SVR Algorithm####

##SVR learning##

m=svm(Horizontal.Feature.g~., data =

z,kernel="radial",gamma=0.5,cost=16 ,tolerance = 0.0001, epsilon = 0.02)

m2=svm(Vertical.Feature.g~., data =

x,kernel="radial",gamma=0.005,cost=150,tolerance = 0.0001, epsilon = 0.02)

s=fitted(m)

```

```

s2=fitted(m2)

LHMAPE<-mean(abs(z$Horizontal.Feature.g.-s)/z$Horizontal.Feature.g.)

LVMAPE<-mean(abs(x$Vertical.Feature.g.-s2)/x$Vertical.Feature.g.)

####SVR test####

Htest=predict(m,w)

Vtest=predict(m2,y)

THMAPE<-mean(abs(w$Horizontal.Feature.g.-Htest)/w$Horizontal.Feature.g.)

TVMAPE<-mean(abs(y$Vertical.Feature.g.-Vtest)/y$Vertical.Feature.g.)

g=cbind(LHMAPE,LVMAPE,THMAPE,TVMAPE)

write.table(g,file = "final.csv",sep = ",",row.names = FALSE)

##plot##

plot(a$Observation,a$Horizontal.Feature.g.,type="l",col=4,xlab="Observation",ylab=
"Horizontal Feature (g)")
points(s,type = "l",col=2)
legend("topleft",pch=c(151,151),col=c(4,2),legend=c("real Degradation"
,"SVR prediction output"))

plot(b$Observation,b$Horizontal.Feature.g.,type="l",col=4,xlab="Observation",ylab=
"Horizontal Feature (g)")

points(Vtest,type = "l",col=2)

legend("topleft",pch=c(151,151),col=c(4,2),legend=c("real Degradation"
,"SVR prediction output"))

```

## 附錄 D. 個案 1 中分析資料的 Code

```
library(e1071)

a=read.table(file = "Learning1.csv",header = TRUE,sep = ",")

z=a[1300:2803,-3]

###SVR Algorithm###

##find P##

obj0 <- tune.svm(Horizontal.Feature.g.~, data = z, kernel="radial", gamma =
seq(0.01, 1, by = 0.01), cost = seq(1, 100, by = 10))

summary(obj0)

##SVR learning##

m=svm(Horizontal.Feature.g.~, data =
z, kernel="radial", gamma=0.01 ,cost=1 ,tolerance = 0.0001, epsilon = 0.02)

s=fitted(m)

LHMAPE<-mean(abs(z$Horizontal.Feature.g.-s)/z$Horizontal.Feature.g.)

LHMAPE

write.table(s,file = "final.csv",sep = ",")

##adjust header##

k=read.table(file = "final.csv",header = TRUE,sep = ",")

p=k[1:1467,]

##plot##

plot(a$Observation,a$Horizontal.Feature.g.,type="l",col=4,xlab="Observation",ylab=
"Horizontal Feature (g)")
```



```

plot(z$Observation,z$HorizontalFeature.g.,type="l",col=4,xlab="Observation",ylab=
"Horizontal Feature (g)")

points(p,type = "l",col=2)

legend("topleft",pch=c(151,151),col=c(4,2),legend=c("real Degradation"
, "SVR prediction"
output"))

```

## 附錄 E. 個案 1 中分析 Bearing1\_3 的 Code

```

library(e1071)

a=read.table(file = "Learning1.csv",header = TRUE,sep = ",")
b=read.table(file = "Test1.csv",header = TRUE,sep = ",")
z=a[822:1802,]

###SVR Algorithm###

##find P##

obj0 <- tune.svm(Horizontal.Feature.g.~, data = z, kernel="radial", gamma = seq(0.5,
5, by = 0.5), cost = seq(1, 100, by = 10))

summary(obj0)

##SVR learning##

m=svm(Horizontal.Feature.g.~, data =
z, kernel="radial", gamma=0.05 ,cost=21 ,tolerance = 0.0001, epsilon = 0.02)

s=fitted(m)

###SVR test###

Htest=predict(m,b)

```



```

plot(Htest,type="l")

write.table(Htest,file = "final.csv",sep = ",")

##adjust header##

k=read.table(file = "final.csv",header = TRUE,sep = ",")

w=k[822:2306,]

##plot##

plot(a$Observation,a$Horizontal.Feature.g.,type="l",col=4,xlab="Observation",ylab=
"Horizontal Feature (g)")

points(w,type = "l",col=2)

legend("topleft",pch=c(151,151),col=c(4,2),legend=c("real Degradation"
, "SVR prediction"
output"))

```

## 附錄 F. 個案 1 中分析 Bearing1\_4 的 Code



```

library(e1071)

a=read.table(file = "Learning1.csv",header = TRUE,sep = ",")

b=read.table(file = "Test1.csv",header = TRUE,sep = ",")

z=a[1126:1139,]

###SVR Algorithm###

##find P##

obj0 <- tune.svm(Horizontal.Feature.g.~, data = z, kernel="radial", gamma = seq(0.5,
2, by = 0.1), cost = seq(1, 100, by = 10))

summary(obj0)

##SVR learning##

```

```

m=svm(Horizontal.Feature.g~., data =
a, kernel="radial", gamma=0.8 , cost=21 , tolerance = 0.0001, epsilon = 0.02)
s=fitted(m)

###SVR test###

Htest=predict(m,b)

plot(Htest,type="l")

write.table(Htest,file = "final.csv",sep = ",")

##adjust header##

k=read.table(file = "final.csv",header = TRUE,sep = ",")

w=k[1126:1172,]

##plot##

plot(a$Observation,a$Horizontal.Feature.g.,type="l",col=4,xlab="Observation",ylab=
"Horizontal Feature (g)")

points(w,type = "l",col=2)

legend("topleft",pch=c(151,151),col=c(4,2),legend=c("real Degradation"
,"SVR prediction"
output"))

```

## 附錄 G. 個案 2 中分析滾動式預測的 Code

```

library(e1071)

z=read.table(file = "PV.csv",header = TRUE,sep = ",")

Lset=z[13:60,]

Tset=z[61:66,]

##find P##

obj0 <- tune.svm(Pmax~., data = Lset, kernel="linear", gamma = seq(0.5, 5, by = 0.5),

```

```

cost = seq(1, 100, by = 10))

summary(obj0)

##SVR training##

m=svm(Pmax~.,data=Lset,kernel="linear",gamma=0.5,cost=1 ,tolerance = 0.0001,
epsilon = 0.02)

p=fitted(m)

LMAPE=mean(abs(Lset$Pmax-p)/Lset$Pmax)

LMAPE

##SVR test##

k=predict(m,Tset)

TMAPE=mean(abs(Tset$Pmax-k)/Tset$Pmax)

TMAPE

write.table(k,file = "k.csv",sep = ",")
write.table(p,file = "p.csv",sep = ",")

##adjust header##

a=read.table(file="k.csv",header = TRUE,sep = ",")

p=read.table(file="p.csv",header = TRUE,sep = ",")

##plot##

plot(z$Time,z$Pmax,col=9,main="7-54 months and predit 55-60
months",xlab="Time",ylab="Pmax")

points(p,type = "l",col=4)

points(x=a$Time,y=a$Pmax,type = "l",col=2)

legend("topright",pch=c(1,151,151),col=c(9,4,2),legend=c("real Degradation"
,"SVR
learning prediction output","SVR prediction output"))

```

